Демонстрація до завдання № 2

Формування підписів до зображень (image captioning) на Flickr8K

Цей ноутбук — приклад для показу на парі. Завдання: за зображенням згенерувати речення, що його описує (англійською — мовою датасету).

Класична схема **encoder–decoder**:

- **encoder** — згорткова нейронна мережа **CNN** (Convolutional Neural Network) **ResNet-50** (Residual Network, 50 шарів), попередньо навчена на ImageNet. Вона перетворює зображення на карту ознак 7×7×2048: 49 ділянок зображення, кожна описана вектором з 2048 чисел;
- **decoder** — рекурентна мережа **LSTM** (Long Short-Term Memory, мережа з довгою короткочасною пам'яттю), яка генерує речення слово за словом.

Порівнюємо дві відомі архітектури:

- **Show and Tell** (Vinyals et al., 2015) — LSTM бачить лише один усереднений вектор зображення;
- **Show, Attend and Tell** (Xu et al., 2015) — на кожному слові механізм **уваги** (attention) обирає, на які з 49 ділянок «дивитись».

Якість оцінюємо метрикою **BLEU** (Bilingual Evaluation Understudy) — часткою n-грам (послідовностей з n слів) згенерованого речення, що збігаються з еталонними підписами.

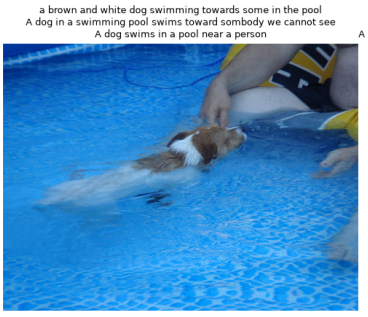
```
Пристрій: mps
```

1. Датасет Flickr8K

8000 фотографій з Flickr (люди, тварини, повсякденні сцени), до кожної — **5 підписів**, написаних різними людьми. Стандартне розбиття: 6000 — навчання, 1000 — валідація, 1000 — тест. Беремо копію з Hugging Face Hub (`jxie/flickr8k` , ~1.1 ГБ).

```
Тестових зображень: 1000
```







2. Encoder: ознаки зображень з ResNet-50

Відкидаємо з ResNet-50 два останні шари (усереднення та класифікатор ImageNet) і беремо вихід останнього згорткового блоку: тензор 2048×7×7. Ознаки рахуємо **один раз** для всіх 8000 зображень і зберігаємо — сама ResNet під час навчання декодера не змінюється (так швидше, і це звичайна практика для невеликих датасетів).

```
Downloading: "https://download.pytorch.org/models/resnet50-11ad3fa6.pth" t
o /Users/vm/.cache/torch/hub/checkpoints/resnet50-11ad3fa6.pth
100%|████████████████████████████████| 97.8M/97.8M [00:06<00:00, 14.9
MB/s]
train      ознаки (6000, 49, 2048), підписів 30000
validation ознаки (1000, 49, 2048), підписів 5000
test       ознаки (1000, 49, 2048), підписів 5000
70 с
```

3. Словник

Розбиваємо підписи на слова (нижній регістр, лише літери), залишаємо слова, що трапляються щонайменше 5 разів у навчальних підписах, решта → `<unk>` (невідоме слово). Службові токени: `<s>` — початок речення, `</s>` — кінець, `<pad>` — доповнення до однакової довжини.

```
Різних слів: 7333,  у словнику (частота >= 5): 2533
Довжина підпису: середня 10.8, 95% підписів <= 18 слів
Найчастіші слова: a, in, the, on, is, and, dog, with, man, of, two, white,
black, boy, are, woman, girl, to, wearing, at, people, water, brown, red,
young
```

4. Decoder: LSTM з увагою і без

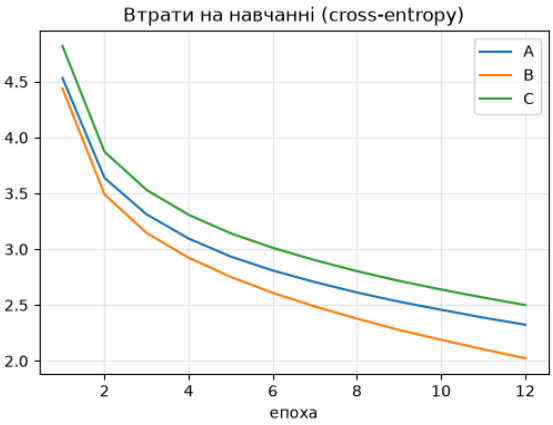
- Початковий стан LSTM (h, c) обчислюється з усередненого вектора зображення.
- На кожному кроці LSTM отримує попереднє слово (через embedding — щільний вектор слова) і передбачає ймовірності наступного слова.
- У варіанті з увагою додатково подається **вектор контексту** — зважена сума 49 ділянок, де ваги α (сума = 1) обчислює невелика мережа з поточного стану LSTM (адитивна увага Bahdanau).

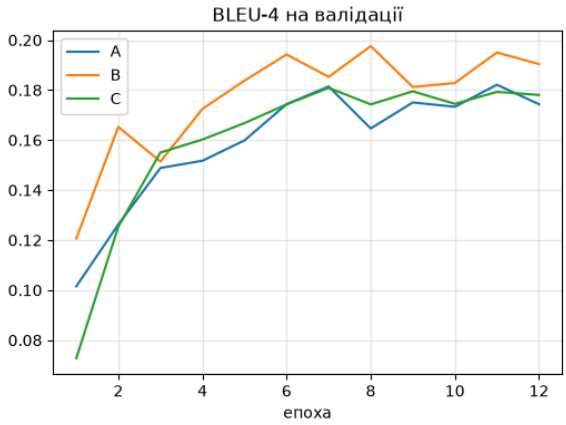
Навчання — **teacher forcing**: на вхід подаємо правильне попереднє слово з еталонного підпису, функція втрат — перехресна ентропія (cross-entropy) між передбаченим і правильним наступним словом.

5. Навчання та експерименти з параметрами (пункт 3 завдання)

Після кожної епохи рахуємо BLEU-4 на валідації і зберігаємо найкращу модель — модель з увагою швидко перенавчається (втрати на train падають, а BLEU на валідації вже не росте).

```
A. Show and Tell (LSTM 512)
   найкраща епоха 11: val BLEU-4 = 0.182, час 171 с
B. Show, Attend and Tell (LSTM 512)
   найкраща епоха 8: val BLEU-4 = 0.198, час 577 с
C. Show, Attend and Tell (LSTM 256)
   найкраща епоха 7: val BLEU-4 = 0.181, час 957 с
```



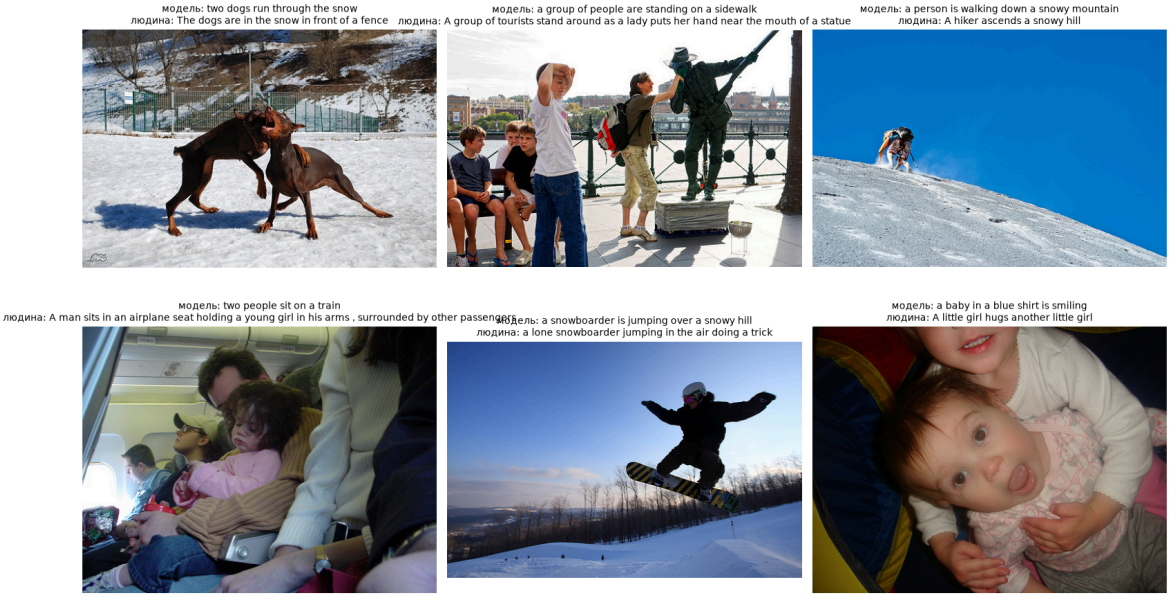


модель	декодування	BLEU-1	BLEU-2	BLEU-3	BLEU-4
A. Show and Tell (LSTM 512)	greedy	0.603	0.422	0.283	0.188
B. Show, Attend and Tell (LSTM 512)	greedy	0.613	0.439	0.301	0.204
C. Show, Attend and Tell (LSTM 256)	greedy	0.602	0.429	0.288	0.190
B. Show, Attend and Tell (LSTM 512)	beam k=3	0.652	0.474	0.336	0.235

(40 с)

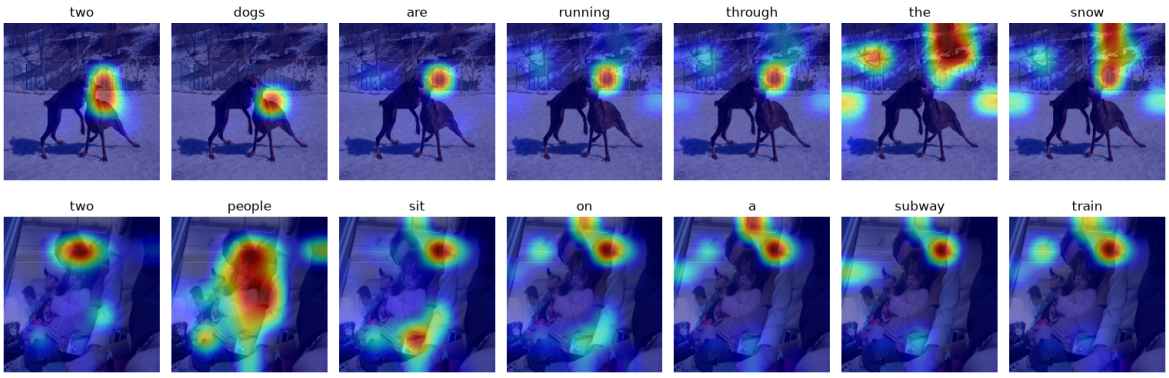
Greedy-декодування на кожному кроці бере найімовірніше слово. **Beam search** (пошук променем) тримає k найкращих часткових речень і обирає найкраще ціле — зазвичай речення виходять природнішими. Для порівняння: в оригінальних статтях на Flickr8K BLEU-4 ≈ 0.18–0.21, тобто наш результат на рівні класичних робіт.

6. Приклади на тестових зображеннях



Куди «дивиться» модель: візуалізація уваги

Для кожного згенерованого слова показуємо ваги α над 49 ділянками зображення (розтягнуто до розміру фото). На іменниках (dog, man, snow...) увага здебільшого зосереджується на відповідному об'єкті, а на службових словах (a, is, the) вона розмита — для них зображення майже не потрібне, модель спирається на граматику.



7. Власні зображення (пункт 4 завдання)

Студенти фотографують 2–3 сцени, типові для Flickr8K (собаки, діти, люди на вулиці, спорт, вода). Тут для прикладу: собака на траві (Wikimedia Commons, CC0), вулиця з автобусом та двоє чоловіків (тестові фото бібліотеки Ultralytics). Функція `caption_file` працює з будь-яким JPG/PNG.

```
dog_grass.jpg    greedy: a brown dog is running on the grass
                 beam:   a brown dog is running through the grass
street_bus.jpg   greedy: a man and a woman are walking down a bus
                 beam:   a group of people walking down the street
two_men.jpg      greedy: a man in a black shirt and black shirt is standin
g in front of a crowd of people
                 beam:   a man in a black shirt is standing in front of a
crowd of people
```



Що обговорити:

- модель добре описує те, що часто бачила: собаки, люди, трава, вода, сніг; автобус теж упізнала, а от двох тренерів на стадіоні описала загально («a man in a black jacket ... in front of a crowd») — таких сцен у Flickr8K мало;
- greedy інколи дає повтори й зайві деталі («a man and a woman in a blue jacket is ...»), beam search — коротші та граматично чистіші речення;
- підписи граматично правильні, але шаблонні — це наслідок малого датасету (30 000 речень);
- BLEU рахує лише збіг слів: синонім чи інший порядок вважаються помилкою, тому навіть два людські підписи до одного фото мають невисокий BLEU між собою.

8. Що має бути у звіті студента

1. Опис Flickr8K, розбиття, побудова словника (розмір, поріг частоти, максимальна довжина).
2. Схема encoder–decoder: яка CNN, розмір ознак, архітектура LSTM / уваги.
3. Таблиця експериментів (архітектура, розмір LSTM, кількість епох, BLEU-1…4), графіки навчання.
4. Порівняння greedy та beam search.
5. Приклади на тестових зображеннях (вдалі та невдалі) і візуалізація уваги.
6. Результати на власних фото та їх аналіз.